

Низкая оценка
– сигнал для
действия.

Прогнозирование
риска помогает
заранее расставить
приоритеты.

Прогнозирование низкой оценки заказа в электронной коммерции

- **Проблема:** бизнес узнаёт о негативном клиентском опыте уже после публикации отзыва.
- **Бизнес-вопрос:** можно ли заранее определить заказы с повышенным риском оценки 1–2 звезды?
- **Цель проекта:** построить модель машинного обучения для прогнозирования низкой оценки.
- **Момент прогнозирования:** после завершения доставки, когда данные о заказе доступны, но отзыв ещё не опубликован.
- **Практический смысл:** использовать прогноз для приоритизации работы клиентского сервиса.

После
доставки риск
становится
управляемым.

Важно понять, как
поддержка может
действовать до
публикации отзыва.

Прогноз низкой оценки помогает вовремя выбрать поддержку

01

Заказ
доставлен

Заказ завершён, и
сведения о доставке
доступны.

*Бразильский маркетплейс
Olist*

02

Прогноз риска

Оценка вероятности
отзыва на 1–2
звезды.

До публикации отзыва

03

Действие
поддержки

Приоритет для
заказов с
повышенным риском
негативного опыта.

*Решение остаётся за
человеком*

Один заказ.
Много
ИСТОЧНИКОВ.

SQL делает связи явными
до начала моделирования.

SQL объединяет девять связанных таблиц в набор данных по заказам

Открытый датасет бразильской электронной торговли Olist · 99 441 заказ до фильтрации




ПРЕОБРАЗОВАНИЕ SQL

JOIN · COUNT(DISTINCT) ·
SUM · AVG · GROUP BY

1 СТРОКА НА ЗАКАЗ

Итоговая структура связывает
признаки и результат отзыва на уровне
заказа.

Задержка доставки связана с ростом доли низких оценок



Доля низких оценок по задержке доставки · 1–2 звезды определяют *bad_review* = 1.

ВЫБОРКА ДЛЯ МОДЕЛИРОВАНИЯ

95 832

доставленных заказов с известными отзывами

87,15% хорошие отзывы
12,85% низкие отзывы

Связь не доказывает причинность. Дисбаланс классов влияет на выбор метрик.

Признаки
доступны
после
доставки, до
публикации
отзыва.

Оценка отзыва — это
целевая переменная,
а не признак.

Две модели оценивают риск по информации после доставки

01

17 признаков

Заказ, оплата, клиент,
товар, время
доставки и задержка.

Оценка отзыва исключена

02

Предобработка

Медианное
заполнение числовых
пропусков; наиболее
частое —
категориальных;
StandardScaler; One-
Hot Encoding.

*Стратифицированное
разделение 80/20*

03

Оценка риска

Logistic Regression и
Random Forest
используют
**class_weight =
balanced.**

*Результат: оценка риска
низкого отзыва*

Random Forest даёт более сильную общую рабочую точку

Модель	Точность	Точность	Полнота	F1-мера	PR-AUC
Logistic Regression	0.7658	0.2935	0.5849	0.3908	0.4102
Random Forest	0.8712	0.4987	0.4630	0.4802	0.4791

Проверенный порог Random Forest: 0,20–0,80 · выбран порог **0,55**, поскольку среди проверенных он максимизировал F1-меру.

ЗАЧЕМ НУЖНЫ ЭТИ МЕТРИКИ


F1 + PR-AUC

Одной точности недостаточно при редком низком отзыве. F1-мера объединяет точность и полноту, а PR-AUC оценивает ранжирование положительного класса при дисбалансе.

В этом сравнении Random Forest — более сильная общая рабочая точка.

Логистика содержит большую часть прогнозного сигнала модели

Признак



Показаны шесть наиболее важных признаков · задержка и время доставки дают около 55% общей важности.

Логистика – самый ясный сигнал.

Характеристики доставки наиболее информативны для модели.

Важность признака показывает прогностическую информативность, а не причинность и не направление эффекта.

Модель помогает расставить приоритеты, но не заменяет решение человека

От доставки – к подходящей поддержке

01

Доставка
завершена

Фактические сведения о доставке доступны.

02

Модель оценивает
риск

Выбранный порог: **0,55**.

03

Найдены заказы
высокого риска

Приоритет до публикации отзыва.

04

Поддержка принимает решение

Уместность контакта определяет человек.

ЗАКАЗЫ В МОДЕЛИ

95 832

ДОЛЯ НИЗКИХ
ОТЗЫВОВ

12,85
%

F1-MEPA RF

0,4802

PR-AUC

0,4791

Данные о доставке — раннее выявление риска

Что показал проект

Данные о заказе после доставки позволяют прогнозировать риск низкой клиентской оценки.

Ключевые результаты

- 95 832 доставленных заказа с известными отзывами
- 12,85% заказов получили низкую оценку 1–2 звезды
- Сравнены Logistic Regression и Random Forest
- Random Forest: F1-score = 0,4802
- Random Forest: PR-AUC = 0,4791
- Наиболее информативные признаки — задержка и длительность доставки

Бизнес-применение

Модель может использоваться для выявления заказов с повышенным прогнозируемым риском и приоритизации работы клиентского сервиса.

Важно

Прогноз показывает риск, а не причинно-следственную связь.

Окончательное решение о взаимодействии с клиентом остаётся за аналитиком.

Финальная мысль: «От данных о доставке — к раннему выявлению риска негативного клиентского опыта».